


Как можно получить переводчик без больших параллельных корпусов данных?

предположения: Языки народов, живущие в похожих условиях, похожи.
Потому что язык описывает мир и в-е од-в между собой.
Получается слова с одним смыслом встречаются в похожих контекстах.

Word embeddings in different languages



идея: даёмте просто отображение одного токена из 1-го языка в другое, выучив какое-нибудь линейное преобразование

- 1) берём n пар слов с 2-х языков и обучаем на них матрицу перевода
- 2) применяем на любое слово и ищем ближайшее
- 3) а даёмте сразу W ортогональной

$$W^* = \operatorname{argmin}_{W \in O_d(\mathbb{R})} \|WX - Y\|_F = UV^T, \text{ with } U\Sigma V^T = \operatorname{SVD}(YX^T).$$

Word embeddings in different languages

- Word embeddings are quite similar for different languages
- Assume there $n = 5000$ word-translation pairs $\{x_i, y_i\}_{i \in \{1, n\}}$
- Learn linear mapping between the source and target spaces

$$W^* = \operatorname{argmin}_{W \in M_d(\mathbb{R})} \|WX - Y\|_F$$

- The translation of source word is $t = \operatorname{argmax}_t \cos(Wx_s, y_t)$.

почему \cos , а не что-то другое?

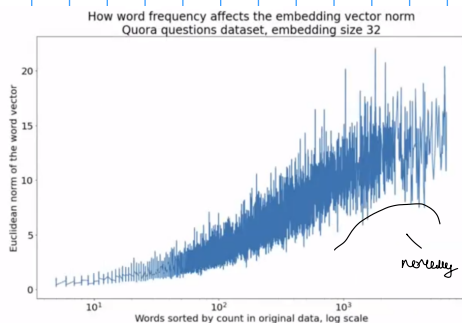
\cos - показывает сопоставленность векторов и не зависит на их нормы.

пример: тексты одной тематики, но разное количество слов будут иметь

(приближая задние нормы эмб-в, но сопоставлены

типа \cos) а норма не сопоставлена эмб-в текстов другой тематики, но близкий по норме близкий

норма вектора в зав-ти от расстояния до нуля



Vector norms for words with no specific context

word	count	vector norm
overheat	11	0.81233
enormous	12	0.807057
dog	1212	11.2591
cat	1545	10.3738
laptop	1906	14.5192
phone	4124	15.7901
a	155726	11.4656
the	252068	8.47355

ответ: общепонятные слова встречаются в разных контекстах. Поэтому при обучении они размещаются далеко от (0, 0, ..., 0)

Поэтому \cos лучше использовать и с эмбедами

Свёртки в работе с текстом

Идея: улавливать локальный контекст, проходясь
фильтрами (окнами)

— CNN лучше эмбеждает фрагменты текста, который
редко бывает без префикса

Что делать с разной длиной входа?

1) RNN

2) адаптивный пулинг

